

AI 서비스를 위한 GPU 클라우드 선택 제안

AI 서비스 준비 중인 팀 가정 · 카카오클라우드 GPU 인스턴스 기반 · 작성자 김준희

1. 가정된 상황

이제 막 AI 기능(추천, 분석 등)을 서비스에 넣으려는 팀이, 모델 학습에는 GPU가 필요하다는 건 알지만 GPU 서버를 상시 띄워두면 비용이 너무 크다는 우려로 클라우드 GPU 도입을 망설이고 있다고 가정합니다.

2. 니즈 분석

표면적 요구	"GPU가 필요한데 비용이 부담스럽다"
실제 니즈	① 학습 시점에만 GPU 비용 지불 ② 실시간 서비스(추론)는 굳이 GPU가 필요한지 판단이 안 됨 ③ 온프레미스 GPU 서버 구매의 초기 투자 부담 회피

3. 근거 — 유사 환경 실측 경험

카카오클라우드 부트캠프에서 진행한 Peakly 프로젝트에서 GPU 인스턴스 운영을 직접 경험했습니다.

카카오클라우드 **gn1i** 인스턴스(NVIDIA T4 GPU, 16vCPU, 64GiB) 1대를 **모델 학습·임베딩 생성에만** 배정
실시간 서비스 응답(추론)은 **CPU 인스턴스**로 분리 운영 — GPU 상시 가동 없이 서비스 지속

GPU와 CPU 워크로드를 분리하면, "학습할 때만 GPU를 켜다"는 구조가 실제로 가능하다는 걸 확인했습니다. 카카오클라우드 GPU 인스턴스는 **사용한 시간만큼만 과금(Pay-as-you-go)**되는 방식이라, 이 분리 구조와 궁합이 좋습니다.

4. 제안 — 학습·추론 워크로드 분리 구조

	학습(Training)	실시간 추론(Serving)
필요 자원	gn1i GPU 인스턴스	일반 CPU 인스턴스
가동 방식	학습 배치 시점에만 가동	상시 가동 (경량)
과금	사용 시간만큼만 (Pay-as-you-go)	일반 인스턴스 요금

초기 온프레미스 GPU 서버 구매 없이, 학습이 필요할 때만 GPU 인스턴스를 띄우고 종료하는 방식으로 시작하는 걸 제안합니다.

목표(KPI): GPU 인스턴스는 학습·배치 작업 시간에만 가동 (상시 가동 대비 가동 시간 최소화), 실시간 서비스는 GPU 없이 CPU만으로 응답 가능한지 우선 검증

범위: 이번 제안은 컴퓨팅 자원 배치 구조에 한정되며, 모델 자체의 정확도·성능 개선은 별도 논의가 필요합니다.

5. 기대 효과

① 온프레미스 GPU 서버 초기 투자 없이 AI 기능 시작 가능 ② GPU 상시 가동 비용 회피 ③ 학습 물량이 늘어나면 GPU 인스턴스 수만 유연하게 조정

※ 이 문서는 실제 고객사 사례가 아니라, 본인이 직접 진행한 Peakly 프로젝트의 실측 경험을 근거로 작성한 가상 연습 자료입니다.